

Estudo de técnicas de detecção de anomalias e suas aplicações

Helena Almeida Victoretti
Luciana de Melo e Abud

TRABALHO DE CONCLUSÃO DE CURSO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
DA
UNIVERSIDADE DE SÃO PAULO

Orientador: Prof. Dr. João Eduardo Ferreira
Coorientador: Dr. Pedro Losco Takecian

São Paulo, 2015

Sumário

1	Introdução	1
1.1	Motivação	1
1.2	Objetivo	2
2	Conceitos e levantamento das principais técnicas	3
2.1	Deteccção de anomalias	3
2.2	Principais técnicas de deteccção de anomalias	3
2.2.1	Baseadas em classificadores	4
2.2.2	Baseadas em distância	8
2.2.3	Baseadas em densidade	8
2.2.4	Baseadas em <i>clustering</i>	9
2.2.5	Baseadas em modelos estatísticos	10
2.3	Validador estatístico de lotes de dados	12
3	Deteccção de anomalias baseada em distância	15
3.1	Método do k-ésimo vizinho mais próximo (kNN)	16
3.1.1	Algoritmo <i>simple nested-loop</i>	16
3.1.2	Algoritmo <i>index-based</i>	17
3.1.3	Algoritmo <i>partition-based</i>	18
3.1.4	Algoritmo <i>nested-loop ANNS</i>	19
3.2	Métricas de distância	20
4	Implementação do módulo de deteccção de anomalias	22
4.1	Detector de anomalias	22
4.2	Algoritmo kNN	23
5	Estudo de caso	26
	Apêndice	27

1 Introdução

Detecção de anomalias refere-se ao problema de encontrar instâncias de um conjunto de dados que apresentam um grande afastamento das demais, ou que são inconsistentes com elas. Tais instâncias são denominadas anomalias. Nas palavras de D. Hawkins [1], anomalia é “uma observação que se desvia tanto das outras observações a ponto de levantar suspeita de que ela foi gerada por um mecanismo diferente”. Por frequentemente indicarem eventos importantes, anomalias requerem uma maior análise para que se possa chegar a uma conclusão sobre suas causas.

Técnicas de detecção de anomalias são úteis em áreas como mineração de dados, limpeza de dados e *data warehousing* [2]. Elas são utilizadas em sistemas com diferentes finalidades. Alguns exemplos são:

- Detecção de invasão em redes de computadores [3; 4]: os padrões de comportamento da rede são analisados e são gerados mapeamentos de transmissão de seus pacotes. Uma anomalia detectada nesses mapeamentos pode indicar uma invasão na rede.
- Verificação de fraude bancária [5]: a detecção de uma anomalia neste contexto pode significar uma fraude no uso de cartão de crédito. As fraudes são refletidas em registros de transações e correspondem a pagamentos de alto valor, compra de itens que nunca foram adquiridos anteriormente pelo cliente, taxa elevada de compras, entre outros.
- Detecção de doença por análise de imagens [6]: a anomalia é detectada no processamento de imagens de ressonância magnética de mama, e pode indicar presença de tumor.

Existem diferentes técnicas de detecção de anomalias que podem ser aplicadas em um conjunto de dados, e cada uma possui suas características. Elas utilizam métodos de diferentes áreas, como aprendizado de máquina, e podem ser baseadas em classificadores, em métodos estatísticos, em distâncias, em densidade, entre outros [7].

A escolha da técnica a ser utilizada depende basicamente do domínio do problema e dos dados de entrada fornecidos [8].

Além de saber aplicar cada técnica, é importante entender a característica e o funcionamento de cada uma.

1.1 Motivação

Um *data warehouse* é um dos principais modelos utilizados para a integração de dados provenientes de diversos bancos de dados distintos, porém um dos principais problemas enfrentados na construção de um *data warehouse* é a consistência dos dados recebidos. Para tentar resolver tal problema foi idealizado um sistema de validação estatística de dados na tese de doutorado de Pedro Takecian [8] e desenvolvido por Eduardo Dias Filho [9].

Esse sistema de validação de lotes foi desenvolvido para o projeto REDS-II (*Retrovirus Epidemiology Donor Study - II*), uma iniciativa cujo intuito é desenvolver projetos de pesquisa com enfoque em segurança transfusional de sangue, e cujo banco de dados armazena dados provenientes de diversos anos de doações de seus hemocentros participantes.

O sistema tem por objetivo validar lotes de dados recebidos pelas diferentes fontes de dados. Um lote de dado, no contexto do validador, é um conjunto de arquivos de dados referentes a um período de funcionamento do sistema transacional.

Esses lotes são recebidos de forma passiva e portanto não há uma garantia sobre a consistência deles. Assim, é necessária uma validação dos lotes recebidos antes que estes sejam inseridos no *data warehouse*, de modo a não tornar o banco inconsistente.

Para manter a corretude dos dados, é preciso verificar se os atributos dos lotes respeitam um determinado domínio e se os dados seguem uma lógica previamente determinada. Essas verificações são as validações sintáticas e semânticas, respectivamente. Entretanto, essas verificações não são suficientes. O sistema de validação descrito acima realiza uma validação estatística dos lotes recebidos, baseada na proporção dos atributos de cada lote recebido.

A validação neste caso consiste em verificar se um lote recebido é válido ou inválido, baseando-se em lotes previamente classificados. Como em geral existem poucos lotes inválidos, para a classificação do lote utiliza-se detecção de anomalias. Assim, a escolha da técnica de detecção a ser utilizada é um importante fator para a eficiência do sistema de validação.

O sistema desenvolvido recebe módulos com implementações de diferentes métodos de detecção de anomalias. Esses métodos são implementados seguindo uma certa interface e obedecendo a certas regras, e depositados no núcleo do sistema como módulos.

Atualmente, o sistema realiza a detecção de anomalias utilizando um módulo baseado em um modelo estatístico. Embora esse modelo seja apropriado para muitas situações, podem existir casos nos quais ele não seja uma boa representação, sendo necessário algum outro método de detecção que se adeque melhor ao problema.

1.2 Objetivo

Este projeto tem como objetivo estabelecer um estudo de caracterização e delimitação de algumas das diferentes técnicas de detecção de anomalias.

Também é de interesse desse trabalho escolher uma técnica de detecção de anomalias que seja adequada ao domínio do problema para ser estudada e implementada em um módulo para o núcleo do sistema de segurança transfusional de sangue. A escolha dessa técnica será um desafio nesse trabalho, uma vez que precisamos encontrar uma técnica que se modele às características dos dados do problema.

Após implementada, a técnica será utilizada em um conjunto de dados a ser escolhido, de modo a testar a implementação e os resultados das análises esperados.

2 Conceitos e levantamento das principais técnicas

2.1 Detecção de anomalias

Anomalias são instâncias de um conjunto de dados que não seguem um comportamento padrão esperado. Essas instâncias não possuem uma característica específica e são de grande interesse para os especialistas do domínio em questão, pois indicam eventos importantes e requerem maior atenção. Elas podem ser univariadas (possuem apenas uma dimensão) ou multivariadas (possuem mais de uma dimensão).

As anomalias podem ser classificadas em três grupos [7; 10]:

1. Anomalias pontuais: uma instância do conjunto de dados é considerada uma anomalia quando comparada com o conjunto todo de dados. São as anomalias mais simples de serem detectadas e possuem o maior número de técnicas de detecção de anomalias.
2. Anomalias coletivas: um subconjunto do conjunto de dados é considerado anômalo, mas as instâncias individuais desse subconjunto não necessariamente são consideradas anômalas.
3. Anomalias contextuais: uma instância do conjunto de dados é considerada uma anomalia em relação a um determinado contexto, mas fora deste não necessariamente é considerada anomalia. Neste caso cada instância de dado é caracterizada por atributos contextuais (que determinam o contexto) e atributos de comportamento (características não contextuais da instância). Uma anomalia contextual também pode ser classificada como pontual ou coletiva.

Detecção de anomalias refere-se ao problema de encontrar instâncias em um conjunto de dados que não possuem um comportamento esperado - as anomalias.

As técnicas de detecção, de modo geral, consistem em determinar quais instâncias de um dado conjunto são anomalias, atribuindo a essas instâncias um rótulo (anomalia ou normal) ou uma pontuação de anomalia [7; 10].

2.2 Principais técnicas de detecção de anomalias

Existem muitas técnicas de detecção de anomalias e o uso de cada uma depende principalmente do conjunto de dados a ser analisado.

Há duas principais fases envolvidas nas técnicas de detecção de anomalias: a fase de treino e a fase de teste. A fase de treino consiste em uma fase inicial do detector de anomalias, em que se define parâmetros utilizados pelo detector a partir de dados do conjunto de treino. A fase de teste consiste em determinar se um dado do conjunto de teste é ou não uma anomalia. O conjunto de teste contém as instâncias a serem classificadas como anomalias ou normais e é normalmente distinto do conjunto de treino [11].

Uma primeira forma de classificação das técnicas leva em conta a rotulação dos dados de treinamento. Uma instância rotulada recebe um rótulo de anomalia ou normal.

Deste modo, as técnicas podem ser divididas em três classes [10]:

- Supervisionadas: assume-se que o conjunto de dados de treino possui instâncias rotuladas como normais ou anômalas.
- Semi-supervisionadas: assume-se que o conjunto de dados de treino possui instâncias rotuladas para apenas uma das classes (anômala ou normal). Normalmente as instâncias normais são as rotuladas, pois acontecem com mais frequência e possuem geralmente um padrão conhecido.

- Não supervisionadas: assume-se que o conjunto de treino não possui instâncias rotuladas.

A técnica de detecção de anomalias pode rotular as instâncias de teste ou identificar uma pontuação de anomalia para cada instância.

Algumas das principais técnicas de detecção de anomalias podem ser classificadas em cinco categorias [7; 10]:

1. Baseadas em classificadores.
2. Baseadas em distância.
3. Baseadas em densidade.
4. Baseadas em *clustering* ¹.
5. Baseadas em métodos estatísticos.

2.2.1 Baseadas em classificadores

Um classificador consegue classificar os dados recebidos entre anômalos ou normais. Essa técnica possui dois estágios: um de treino e um de teste.

Existem quatro principais subcategorias:

1. Baseada em Redes Neurais: Pode ser utilizada para classificação dos dados em uma classe ou em mais de uma classe [10]. Uma rede neural é um dispositivo de processamento que baseia-se na estrutura dos neurônios dos seres vivos. Ele é tipicamente organizado em camadas, como ilustrado na Figura 1 [12].

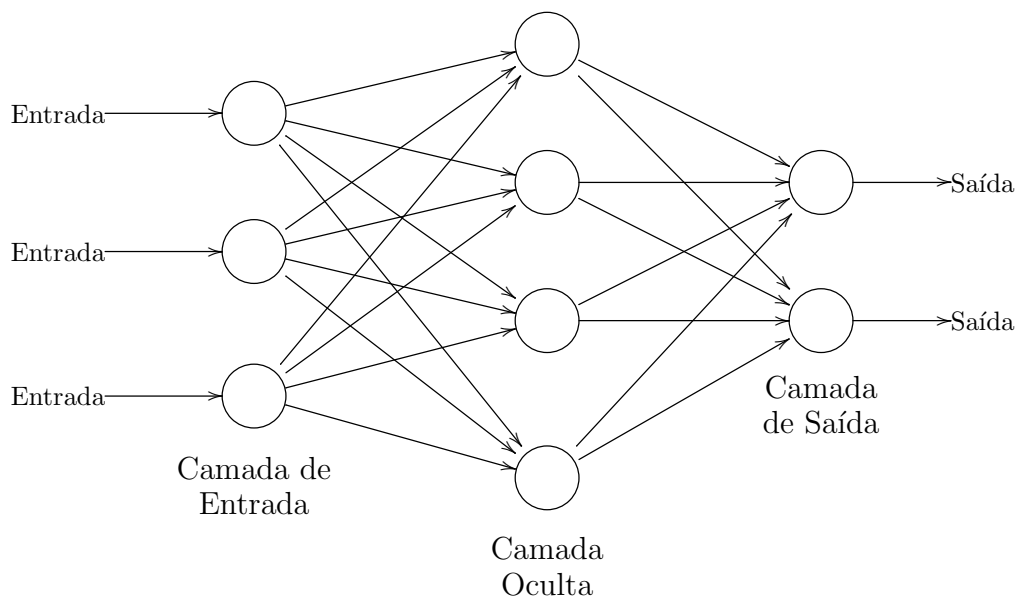


Figura 1: Exemplo da estrutura de uma rede neural

A primeira camada corresponde às instâncias de entrada e a última às classes de saída (ou à classe de saída), e pode existir mais de uma camada oculta entre elas.

¹Neste trabalho, o termo *clustering* não será traduzido para “agrupamento” por ser um termo reconhecido na área na sua forma em inglês.

Cada conexão entre dois nós é associada a um peso, e os valores de saída dos nós são determinados por uma função aplicada a eles. Os valores dos nós da camada de entrada são determinados pelos dados de entrada, enquanto que os valores dos demais nós são calculados a partir dos valores da função de ativação aplicada aos nós das camadas anteriores e dos pesos das arestas de conexão. [13].

Na fase de treino, a rede neural aprende valores para os pesos das arestas de forma que, para qualquer instância de entrada rotulada, a saída seja uma boa aproximação do rótulo [14]. Para isso, os pesos são modificados camada por camada de modo a minimizar o erro do resultado. Já no estágio de teste a rede recebe uma instância, e se ela obtiver o rótulo de uma classe normal é classificada como normal, senão como anômala [10].

Um exemplo de aplicação dessa técnica é a detecção de fraude de cartão de crédito. John Akhilomen[15] desenvolveu um sistema de detecção para *cyber credit card fraud*. *Cyber credit card fraud* pode ser definido como a utilização de informações roubadas de cartões de crédito para compras e/ou pagamentos na internet.

O sistema utiliza detecção de anomalias supervisionada baseada em Redes Neurais, e através de dados referentes ao comportamento padrão do usuário verifica se a transação que está sendo executada é ou não fraudulenta. Na fase de treino, a Rede Neural utiliza como dados as informações sobre a localização geográfica, o *e-mail* e telefone cadastrado, os tipos de produtos e serviços comprados e os sites normalmente utilizados pelo usuário nos últimos um ou dois anos. A figura 2 abaixo ilustra um diagrama de representação da Rede Neural utilizada:

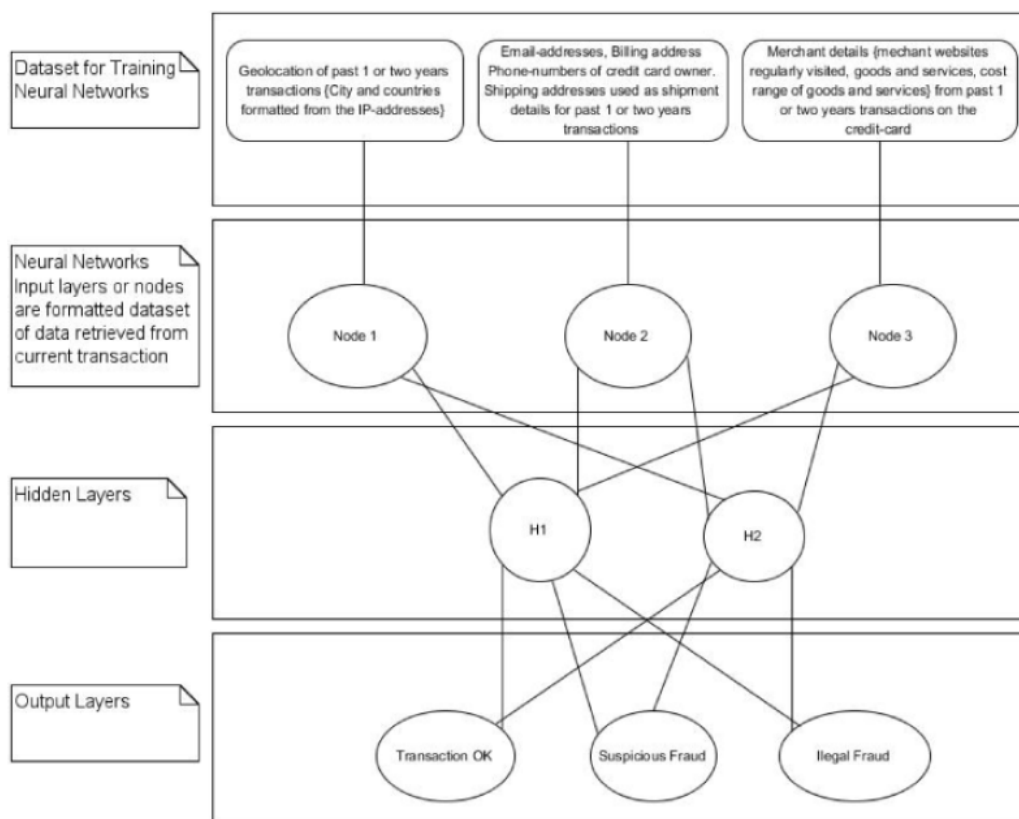


Figura 2: Rede Neural do sistema. Fonte: Data Mining Application for Cyber Credit-card Fraud Detection System de John Akhilomen [15]

Um outro exemplo de uso dessa técnica é o algoritmo proposto por Ghosh et al. [16] que utiliza redes neurais para detectar ataques a rede de computadores, classificando os

dados recebidos entre normais e anômalos.

2. Baseada em Redes Bayesianas: Utilizada em classificação com uma ou mais de uma classe e com instâncias rotuladas na fase de treino. Uma rede Bayesiana é uma estrutura gráfica probabilística, representada por um digrafo acíclico, em que cada nó do grafo representa uma variável aleatória X_i ($i \in \{1, 2, \dots, d\}, d \in \mathbb{N}$), e as arestas representam dependências probabilísticas entre as variáveis [17]. Essa rede define uma distribuição de probabilidade conjunta, dada por:

$$P(X_1, X_2, \dots, X_d) = \prod_{i=1}^d P(X_i | \Pi_{X_i}),$$

em que Π_{X_i} é o conjunto de todos os pais de X_i (nós que são origem das arestas que têm destino em X_i) [18].

A estrutura de um classificador simples baseado em rede Bayesiana é dada como na figura abaixo:




Figura 3: Exemplo da estrutura de uma rede Bayesiana simples.

Nesse caso, o nó raiz é o nó que representa a variável de classe, e cada nó que representa as variáveis de dimensão tem como único pai o nó de classe. Ou seja, $\Pi_C = \emptyset$ e $\Pi_{X_i} = \{C\}$, para todo $1 \leq i \leq d$.

Assim, na fase de treino, calcula-se a probabilidade $P(C = c_k)$ ($k \in \{1, \dots, K\}$), que é a probabilidade de uma instância pertencer à classe c_k , em que K é o número de classes do problema. Na fase de teste, ao receber uma instância (x_1, x_2, \dots, x_d) de dimensão d , calcula-se a probabilidade condicional de cada classe, dada por:

$$P(C = c_k | X_1 = x_1, \dots, X_d = x_d) = P(C = c_k) \cdot \prod_{i=1}^d \frac{P(X_i = x_i | C = c_k)}{P(X_i = x_i)}.$$

A instância pode ser então atribuída à classe com a maior probabilidade. Se a probabilidade de cada classe for baixa, então a instância é classificada como anômala [19]. Uma outra abordagem considera a existência de apenas duas classes: a de instâncias normais e a de anomalias, e atribui a instância a ser analisada à classe de maior probabilidade [20].

Um exemplo de aplicação dessa técnica é um sistema de detecção de intrusão em redes desenvolvido por Sebyala et al. [20]. Nessa abordagem, o comportamento do sistema é analisado (considerando uso de CPU e memória, por exemplo) de forma a detectar possíveis invasões ou ataques. A variável de classe C pode assumir dois valores: verdadeiro (indicando um possível ataque ao sistema) e falso (indicando um comportamento normal). São utilizadas ainda variáveis binárias para representar atributos observados do sistema, como por exemplo, X_1 e X_2 indicando uso de CPU acima de 90% e uso de memória acima de 70%, respectivamente. Nesse modelo assume-se que os atributos observados (X_1 e X_2) são condicionalmente independentes dado o valor da classe C .

Outras aplicações podem ser destacadas em áreas como detecção de fraudes em redes de comunicação (como redes de telefonia celular) [21], detecção de atividades suspeitas através de imagens de sistemas de vigilância [22] e detecção de intrusão a redes de computadores [23].

3. Baseada em Máquinas de Vetores Suporte (*Support Vector Machines*): Utilizada em classificação com uma classe normal. A ideia principal dessa técnica é encontrar uma fronteira de separação entre duas classes - a de instâncias normais e a de anomalias [24].

Um exemplo de uma fronteira de separação é ilustrado na figura 4.




Figura 4: Exemplo de uma fronteira de separação entre instâncias normais (em preto) e uma instância anômala (em vermelho).

No estágio de treino, aprende-se a fronteira da região dos dados normais. No estágio de teste, para cada instância recebida, verifica-se se ela está dentro ou fora da fronteira. Se estiver dentro é classificada como normal, se estiver fora, como anômala [10].

Um exemplo do uso dessa técnica foi dado na realização de testes de motores de jatos. Através da observação das vibrações, Hayton et al. [25] utiliza SVM para detectar vibrações anormais. Os dados utilizados para isso são médias ponderadas das amplitudes das vibrações dos motores para dez diferentes intervalos de velocidade, obtendo assim instâncias de dimensão 10.

4. Baseada em Regras: Utilizada em classificação com uma ou mais de uma classe normal. A classificação das instâncias é baseada em um conjunto de regras da forma “se, então”, que definem um conjunto de condições que devem ocorrer para que uma determinada decisão seja tomada [26]. Na fase de treino aprendem-se as regras sobre as quais os dados normais se comportam, utilizando algoritmos de aprendizagem de regras. Na fase de teste, se nenhuma regra captura a instância de teste, ela é considerada anômala, caso contrário é considerada normal [10].

Um exemplo do uso dessa técnica é na detecção de anomalias em tráfego de dados em redes de computadores, Mahoney et al. [27] desenvolveu um sistema que aprende regras para detectar tais anomalias. Um outro exemplo é o sistema de detecção precoce de surtos de doenças desenvolvido por Wong et al. [28] que busca por padrões anômalos em dados provenientes de departamentos de emergência, aprendendo regras que caracterizam tais padrões.

As vantagens desse tipo de técnica são a existência de muitos algoritmos poderosos de classificação e a rapidez do processo da fase de teste. As desvantagens são a necessidade de os dados de entrada serem rotulados e a falta de uma pontuação de anomalia associada às instâncias (apenas são classificadas como normais ou anômalas).

2.2.2 Baseadas em distância

As técnicas dessa categoria levam em consideração a distância entre uma instância do conjunto de dados a ser analisada e seus vizinhos. Dependendo do tipo do dado de entrada utilizam-se diferentes métodos para determinar a distância [29]. Para dados multivariados, normalmente, calcula-se a distância para cada uma das dimensões separadamente e depois os resultados são unidos.

Há duas principais subcategorias:

1. Método da vizinhança local : A ideia desse método é encontrar os vizinhos locais de uma determinada instância p . Se uma quantidade menor que k (definida previamente) de instâncias está a uma distância D ou menor que D (definida previamente) de p , então p é considerada uma anomalia. Uma anomalia neste contexto pode ser chamada de $DB(k, d)$ -Outlier [7]. Para obter os vizinhos de uma dada instância pode-se utilizar um dos seguintes algoritmos: *nested-loop algorithm*, *index-based algorithm* ou *cell boxed algorithm* [30]. Esse método não atribui uma pontuação para as instâncias classificadas como anomalias, o que para algumas aplicações pode ser uma desvantagem.
2. Método do k-ésimo vizinho mais próximo ($kNN - k$ nearest neighbors): Nesse método cada instância é associada a uma pontuação de anomalia, que é calculada a partir da sua distância ao seu k-ésimo vizinho mais próximo (o valor de k é definido previamente) [7; 10]. Quanto maior a distância maior sua pontuação de anomalia. A determinação das instâncias anômalas se obtém selecionando as n (definido previamente) instâncias que possuem maior pontuação de anomalia, ou seja, maior distância ao seu k-ésimo vizinho mais próximo. Como no método anterior, pode-se utilizar um dos seguintes algoritmos para encontrar tal distância: *nested-loop algorithm*, *index-based algorithm* ou *partition based algorithm* [31]. A ideia deste método pode ser estendida para a k-ésima região densa mais próxima.

Um exemplo de utilização desse método é detectar através de imagens de vídeo comportamentos humanos anômalos. Os dados utilizados por Leeuwen et al. [32] na detecção de comportamentos anômalos não possuem uma distribuição homogênea, por isso utilizam esse método.

A vantagem desse tipo de técnica é que não é levada em consideração nenhuma característica especial dos dados de entrada. Eles não precisam ser rotulados, ou possuir uma distribuição estatística (como as técnicas baseadas em modelos estatísticos descritas na seção 2.2.5) [7; 29]. As desvantagens são o fato dessas técnicas suporem a existência de métricas de distância adequadas para estabelecer a semelhança entre dois pontos [29] e a ineficiência da maior parte dessas técnicas quando as instâncias são multivariadas e possuem uma alta dimensionalidade [7]. Porém existem estudos que tentam desenvolver algoritmos eficientes para essas técnicas [30; 31; 33; 34].

2.2.3 Baseadas em densidade

As técnicas dessa categoria estimam a densidade da vizinhança de cada instância. Uma instância que pertence a uma vizinhança pouco densa é considerada anomalia.

Essas técnicas são, geralmente, mais complexas que as baseadas em distância, portanto são mais caras computacionalmente. A diferença entre as técnicas que pertencem a essa categoria são os métodos utilizados para atribuir a pontuação de anomalia as instâncias.

Os principais métodos são:

1. *LOF (Local Outlier Factor)*: Para qualquer instância de dados, a pontuação *LOF* é igual à razão entre a densidade local média dos k vizinhos mais próximos da ocorrência e a densidade local da instância em si [10; 35].
2. *COF (Connectivity-based Outlier Factor)*: A principal diferença entre *LOF* e *COF* é a forma como são calculadas as k vizinhanças mais próximas de uma dada instância. Em *COF* as vizinhanças são calculadas de modo incremental. Depois de calculada a vizinhança, a pontuação *COF* é calculada do mesmo modo que a pontuação *LOF*. A pontuação *COF* é melhor que a *LOF*, pois consegue capturar regiões que são linhas retas. Porém é computacionalmente mais cara [10; 36].
3. *ODIN (Outlier Detection using In-degree Number)*: Para uma dada instância p , o valor *ODIN* é igual ao número dos k vizinhos mais próximos da instância que possui p como um dos k vizinhos mais próximos. A pontuação de anomalia é o inverso do valor *ODIN* [10].
4. *INFLO (Influenced Outlierness)* Há situações em que o *LOF* não consegue caracterizar as anomalias corretamente, como por exemplo, quando há duas regiões com densidades distintas próximas uma da outra. Para isso o *INFLO* usa além dos vizinhos mais próximos, os valores de vizinho mais próximo reverso, que são os pontos que possuem a instância como um dos vizinhos mais próximos [7].
5. *MDEF (Multi-granularity Deviation Factor)*: O *MDEF* de uma instância p é igual ao desvio padrão das densidades locais dos vizinhos mais próximos da instância p (inclusive a própria p). O inverso de *MDEF* é a pontuação de anomalia da instância [10].

Um módulo de detecção de intrusões a rede de computadores, denominado MINDS (*Minnesota Intrusion Detection System*), foi implementado por Etzos et al. [37] utilizando o método *LOF* para atribuir pontuações de anomalia para os dados.

As vantagens das técnicas dessa categoria são a eficiência (geralmente se mostram mais eficazes que as técnicas baseadas em distância) e a possibilidade de serem utilizadas em dados não rotulados. A desvantagem é o custo computacional em relação às técnicas baseadas em distância.

2.2.4 Baseadas em *clustering*

Clustering é um método utilizado para agrupar dados similares. Essa técnica pode ser dividida em três subcategorias que levam em consideração diferentes regras para determinar uma anomalia [10]:

1. Regra 1: Assume-se que instâncias normais pertencem a algum *cluster*² e instâncias anômalas a nenhum.
2. Regra 2: Assume-se que uma instância normal está próxima do centro do *cluster* mais próximo e uma instância anômala está distante do centro do *cluster* mais próximo.
3. Regra 3: Assume-se que instâncias normais pertencem a *clusters* grandes e densos, enquanto instâncias anômalas pertencem a *clusters* pequenos e esparsos.

Utilizando as regras 1 e 2, se as anomalias formarem um *cluster*, elas não serão detectadas.

Um algoritmo de *cluster* basicamente agrupa as instâncias em K grupos disjuntos, em que K é um inteiro positivo. O algoritmo em geral segue quatro passos:

²Neste trabalho, o termo *cluster* não será traduzido para “grupo” por ser um termo reconhecido na área na sua forma em inglês.

1. Define o número K de *clusters*
2. Inicializa os centros dos K *clusters*. Isso pode ser feito dividindo arbitrariamente todas as instâncias de treino entre os K *clusters*, calculando seus centros e verificando que são todos distintos entre si. Uma outra alternativa seria escolher arbitrariamente K instâncias de treino distintas e inicializá-las como os centros dos *clusters*.
3. Para cada instância de treino, calcula sua distância ao centro de cada *cluster*, e atribui a instância ao *cluster* cujo centro é o mais próximo.
4. Recalcula os centros de cada *cluster* modificado.
5. Repete o passo 3 até que os centros não mudem mais.

Para o cálculo da distância entre as instâncias e os centros pode-se utilizar diferentes métodos, como por exemplo a função de distância Euclidiana, dada pela fórmula:

$$F(x, y) = \sqrt{\sum_{i=1}^d (x_i - y_i)^2},$$

em que d é a dimensão de cada instância e $x = (x_1, \dots, x_d)$ e $y = (y_1, \dots, y_d)$ são dois vetores de dimensão d .

A grande diferença entre as técnicas baseadas em *clusters* e as baseadas em distância (vizinhos mais próximos) é que nas baseadas em *clusters* a instância é analisada em relação à sua distância aos *clusters*, enquanto a baseada em distância é analisada em relação à sua vizinhança local.

Um exemplo de aplicação dessa técnica é na detecção de fraude de cartão de crédito. Bolton et al. [38] idealizou um mecanismo de detecção de fraude em cartão de crédito que utiliza detecção de anomalias baseada em *clusters*. A diferença principal entre essa técnica e a técnica utilizada no sistema baseado em redes neurais de John Akhilomen [15] descrito na seção 2.2.1 é a sua propriedade de ser não supervisionada.

A técnica consiste em criar *clusters* de transações similares, em que o perfil de uma conta seria determinado pelos *clusters* que possuem transações dessa conta. Uma transação anômala de uma conta seria uma transação que não pertenceria ao perfil da conta, ou seja, não pertenceria a nenhum dos *clusters* que possuem transações da conta. O grande problema dessa técnica seria a escolha das variáveis e métricas de distância utilizadas.

Um outro exemplo do uso dessa técnica é na detecção de invasões em redes. Leung et al. [39] utiliza detecção de anomalias baseadas em *clustering* para detectar invasões em redes, através de dados não rotulados.

As vantagens dessas técnicas são a possibilidade de serem utilizadas com dados não rotulados, a existência de muitos algoritmos de *clustering* e a rapidez do processo da fase teste. A desvantagem é a dependência dos algoritmos de *clustering* que não são adaptados para detectar anomalias, mas sim para formar *clusters* [7; 10].

2.2.5 Baseadas em modelos estatísticos

As técnicas dessa categoria se baseiam no fato de que existe uma distribuição estatística que modela o conjunto de dados. As instâncias anômalas são as que não são modeladas por essa distribuição.

Na fase de treino um modelo estatístico é generalizado para o conjunto de dados e na fase de teste, se uma instância não corresponde ao modelo, ela é considerada como anômala.

Existem duas subcategorias de métodos [7; 10]:

1. Métodos paramétricos: Assume explicitamente um modelo estatístico para o conjunto de dados.

- a. Baseado no Modelo Gaussiano: Assume-se que os dados são gerados através de uma distribuição gaussiana. A fase de treino normalmente utiliza *MLE* (*Maximum Likelihood Estimates*) para determinar a média e o desvio padrão da distribuição gaussiana. Na fase de teste utiliza-se uma métrica para determinar as instâncias anômalas. Dentre elas, podemos destacar:
- Teste da média-variância: Se uma instância está a uma distância maior que três vezes o desvio padrão, então é considerada anômala.
 - Teste do *box-plot*: Através do *box-plot*, calcula-se o *IQR* (*Inter quartile range*), o quartil 1 (Q1) e o quartil 3 (Q3). Se uma instância estiver a uma distância de $1.5 \cdot \text{IQR}$ de Q1 ou a uma distância de $1.5 \cdot \text{IQR}$ de Q3, é considerada anômala [7; 29].
 - Teste Grubb: Para instâncias univariadas, é obtido pela fórmula:

$$G = \frac{|Y_i - \bar{Y}|}{s}, i \in \{1, 2, \dots, N\},$$

[10] onde Y_i é a instância, \bar{Y} é a média, s é o desvio padrão.

- iv. Qui-quadrado: Para instâncias multivariadas pode-se utilizar a média de qui-quadrado dada pela fórmula:

$$\chi^2 = \sum_{i=1}^N \frac{(X_i - E_i)^2}{E_i}, i \in \{1, 2, \dots, N\},$$

[10] onde E_i é o valor esperado da i -ésima característica da instância X e X_i é a i -ésima característica da instância X .

b. Modelo de Regressão [10]:

- Encontrar um modelo de regressão que se encaixe no conjunto de dados.
- Para cada instância de teste, o residual (parte da instância que não é explicada pelo modelo de regressão) é usado para determinar a pontuação de anomalia da instância.

c. Mistura de distribuições paramétricas estatísticas [10]:

- Utiliza uma distribuição para modelar as instâncias normais e outra para modelar as instâncias anômalas.
- Utiliza uma mistura de distribuições paramétricas para modelar as instâncias normais. Se nenhuma distribuição modelar uma dada instância, então esta será considerada anômala.

2. Métodos não-paramétricos: Usa um modelo estatístico não paramétrico, tal que a estrutura da distribuição dos dados não é definida previamente, mas obtida a partir do conjunto de dados .

a. Baseada em Histogramas [7; 10]:

- Instâncias univariadas: Obtém-se o histograma a partir do conjunto de dados de treino. Na fase de teste é verificado se a instância cai em alguma das “torres” do histograma. Se cair é considerada normal, senão anômala. Outro modo de fazer a fase de teste é atribuir como pontuação de anomalia a “altura da torre” a qual a instância pertence.

- ii. Instâncias multivariadas: Constrói-se um histograma para cada característica das instâncias.
- b. Baseada em função kernel: Utiliza-se uma função kernel para obter uma aproximação da função de densidade da distribuição dos dados. Uma instância de teste é declarada como anômala se obtém um valor baixo para a função de densidade da distribuição. Pode ser usada para instâncias univariadas ou multivariadas [7; 10].

Um exemplo do uso dessa técnica é na detecção de ataques na *web*. Kruegel et al. [40] utiliza diferentes técnicas baseadas em modelos estatísticos para detecção de anomalias que poderiam ser determinadas como ataques na *web*.

As vantagens dessas técnicas são a existência de uma justificativa matemática para a classificação da instância entre anomalia ou normal, a possibilidade de serem usadas em dados não rotulados e a eficiência quando se obtém uma boa função de densidade da distribuição dos dados a serem analisados. As desvantagens são a necessidade dos dados seguirem uma distribuição estatística, o aumento da dificuldade de encontrar uma distribuição que modele o conjunto de dados quanto maior sua dimensionalidade, além de possuírem uma performance limitada quando há poucas instâncias de treino [7; 10; 29].

2.3 Validador estatístico de lotes de dados

A integração dos dados em um *data warehouse* é feita através de um sistema integrador. Esse sistema pode extrair os dados dos bancos de dados envolvidos de forma ativa ou passiva. A forma mais utilizada é a extração passiva, pelo fato de que na forma ativa o sistema integrador precisa ter acesso a vários bancos de dados de instituições distintas, o que nem sempre é possível. A extração de dados passiva exige que seja estabelecido um formato de como os dados devem ser enviados para o sistema integrador. Nesse sistema, uma estrutura de lote de dados é utilizada para o recebimento dos dados, que consiste em um conjunto de arquivos em que cada linha do arquivo corresponde a um registro da tabela de um banco de dados relacional. Tal conjunto de arquivos corresponde a dados extraídos de um sistema transacional referentes a um período de funcionamento desse sistema.

Com a extração passiva dos dados, perde-se a confiabilidade na correção dos dados recebidos. Portanto o sistema integrador precisa realizar uma validação dos lotes recebidos. O processo de validação é constituído de regras sintáticas e semânticas que têm por objetivo verificar a correção do formato dos dados recebidos. Porém, essas regras não conseguem verificar alguns erros, como por exemplo: Seja l um lote que está com o formato correto, mas uma análise global dos dados mostra que as proporções dos atributos nos lotes não estão corretas. Essa verificação não consegue ser feita pelas regras sintáticas e semânticas.

Para resolver tal problema, foi desenvolvido um sistema validador estatístico dos lotes de dados. Esse validador utiliza medidas estatísticas dos lotes de dados para verificar a validade destes.

O método de validação estatística dos lotes de dados consiste em decidir se um determinado lote é válido ou inválido, baseando-se em lotes já classificados. O problema de classificação possui três características importantes: a quantidade de lotes inválidos é pequena, os lotes inválidos são importantes para a detecção de onde os erros estão sendo produzidos e os lotes inválidos não possuem uma característica comum. Por esses três fatores o método de validação estatística utiliza detecção de anomalias.

A medida estatística extraída dos lotes utilizada pelo validador é a proporção dos valores dos atributos de interesse do lote. Para obter tais proporções os atributos precisam possuir categorias, portanto é preciso dividir os atributos numéricos em intervalos tal que cada intervalo consiste em uma categoria. Assim para cada atributo de interesse, ou seja, que se quer

validar, obtemos as proporções de cada categoria. As tabelas 1 e 2 exemplificam as proporções de um atributo categórico e de um atributo numérico respectivamente.

Fator Rh sanguíneo	Proporção no lote
Positivo	0.46
Negativo	0.45
Indeterminado	0.09

Tabela 1: *Proporções em um lote exemplo das categorias do atributo fator Rh sanguíneo*

Faixa etária	Proporção no lote
idade < 18	0.00
$18 \leq \text{idade} < 28$	0.25
$28 \leq \text{idade} < 38$	0.22
$38 \leq \text{idade} < 48$	0.23
$48 \leq \text{idade} < 58$	0.19
$58 \leq \text{idade} < 68$	0.10
$68 \leq \text{idade}$	0.01

Tabela 2: *Proporções em um lote exemplo do atributo numérico faixa etária já categorizada*

Assim podemos modelar a validação dos lotes como detecção de anomalias, em que cada lote consiste em vetores de características cujas dimensões são as proporções encontradas nos lotes, onde cada vetor representa um atributo de interesse. Por exemplo, considere um lote que contém os seguintes atributos e categorias:

- Tipo sanguíneo: A, B, AB, O, desconhecido
- Gênero: M (masculino), F (feminino), outros
- Estado civil: casado, solteiro, divorciado, viúvo, outros

Então, os vetores x, y, z de características que representam esse lote podem ser descritos como:

$$\begin{aligned}x &= (x_1, x_2, x_3, x_4, x_5) \\y &= (y_1, y_2, y_3) \\z &= (z_1, z_2, z_3, z_4, z_5)\end{aligned}$$

Neste caso, o vetor x contém proporções das categorias do atributo tipo sanguíneo, y contém proporções das categorias do atributo gênero e z contém as proporções das categorias do atributo estado civil.

Cada um desses vetores é uma instância em um detector de anomalias, ou seja, para validar esse lote seriam necessárias três instâncias de detector de anomalias. Essa divisão é feita porque a dimensão do vetor seria muito grande se fosse utilizado um único vetor de características para representar um lote, podendo causar problemas na detecção de anomalias, uma vez que quanto maior a dimensão, mais lotes de treinamento seriam necessários. Além disso, não seria possível descobrir qual ou quais atributos são responsáveis pelo comportamento anômalo.

Nesse contexto, chamamos de validador global o validador que valida o lote como um todo e de validador individual o validador que valida cada atributo do lote.

Os validadores individuais não precisam receber o lote inteiro. Eles podem receber apenas dados referentes ao atributo que irão validar, o que será chamado de lote reduzido.

Assim, podemos definir o processo de validação V de um lote l com n atributos de interesse do seguinte modo:

Sejam v_1, v_2, \dots, v_n os validadores individuais e sejam l_1, l_2, \dots, l_n os respectivos lotes reduzidos. Então:

$$V(l) = v_1(l_1) \wedge v_2(l_2) \wedge \dots \wedge v_n(l_n).$$

Ou seja, V será válido para o lote l se todos os lotes reduzidos de l forem válidos. Caso contrário, V será inválido para l .

Esse sistema de validação foi idealizado por Pedro Takecian em sua tese de doutorado [8].

3 Detecção de anomalias baseada em distância

Nesta seção explicaremos a escolha da técnica de detecção de anomalias baseada em distância a ser implementada como um módulo do sistema validador descrito da seção 2.3. Faremos também um estudo mais detalhado da técnica escolhida, apresentando seus principais algoritmos e um estudo sobre a escolha da função de distância a ser utilizada.

O módulo desenvolvido para o detector de anomalias do sistema é baseado no modelo de detecção gaussiana, que modela adequadamente muitas situações, mas em alguns casos algum outro método é necessário para representar melhor o problema. A figura 5 exemplifica um caso em que o modelo gaussiano não representa as instâncias apropriadamente, em que se desconhece a razão das instâncias se agruparem em dois conjuntos distintos.




Figura 5: Exemplo de instâncias que não são adequadamente representadas pelo modelo gaussiano. Fonte: Pedro L. Takecian. Diretrizes metodológicas e validação estatística de dados para a construção de data warehouses, 2014 [8].

Uma técnica baseada em distância se adequaria a essa situação, bem como uma baseada em densidade e *clustering*. Entretanto devido ao custo computacional das técnicas baseadas em densidade e devido ao fato dos algoritmos de *clustering* não serem aptos a encontrarem anomalias, mas a formar *clusters*, escolhemos como objeto de estudo as técnicas baseadas em distância.

Não foram escolhidas as técnicas baseadas em classificadores por serem em geral dependentes de dados rotulados, de tal forma que seria necessária uma grande quantidade de lotes válidos e inválidos de treinamento para uma melhor performance da técnica. Além disso, essas técnicas dependem de algoritmos de classificação que não são aptos a encontrar anomalias, mas sim a subdividir um conjunto de dados em classes.

No contexto de técnicas baseadas em distância não é feita nenhuma hipótese sobre os dados, e elas generalizam muitos conceitos de métodos que assumem que os dados seguem uma certa distribuição (como métodos estatísticos) [7]. Dessa forma, um módulo de detector de anomalias baseado em distância se adequa ao domínio do problema do sistema de validação.

Existem dois principais tipos de técnicas baseadas em distância: o método da vizinhança local e o método do k-ésimo vizinho mais próximo (apresentado normalmente como kNN). A principal diferença entre esses dois métodos está na definição de anomalia.

Uma anomalia no contexto da vizinhança local pode ser chamada de *DB-outlier* (*distance based outlier*) [30], e é definida como:

“Uma instância O em um conjunto T de dados é um *DB(p, D)-outlier* se pelo menos uma fração p ($0 < p < 1$) de instâncias em T se encontra a uma distância maior que D de O .”

Uma anomalia no contexto do k -ésimo vizinho mais próximo pode ser chamada de *D_n^k -outliers* [31], e é definida como:

“Dado um conjunto de entrada com N instâncias e parâmetros n e k , uma instância p é um *D_n^k outiler* se não mais que $n - 1$ outras instâncias p' possuem $D^k(p') > D^k(p)$.”

Nessa definição, n representa a quantidade de anomalias a serem encontradas e $D^k(p)$ a distância entre p e seu k -ésimo vizinho mais próximo. Além disso, $D^k(p)$ representa uma pontuação de anomalia, ou seja, quanto maior o $D^k(p)$, maior o grau de anomalia de p .

A principal diferença entre as definições de anomalia dos dois métodos é a necessidade de definir o parâmetro adicional D para detectar os *DB-outliers*, que é muitas vezes difícil de ser encontrado [31; 34], porém para obter os *D_n^k -outliers* é preciso definir previamente a quantidade de anomalias que se deseja encontrar. Além disso, pela definição de *DB-outlier* não se atribui às anomalias uma pontuação.

Como no sistema de validação deve-se decidir se um determinado lote recebido é válido ou inválido, o parâmetro n do método do k -ésimo vizinho mais próximo não será utilizado, uma vez que não precisaremos encontrar n anomalias no conjunto de dados, e sim decidir se uma dada instância é anômala ou não levando em consideração os lotes de treinamento.

Sendo assim, optamos pelo método do k -ésimo vizinho mais próximo para estudo e implementação do módulo do sistema de validação.

3.1 Método do k -ésimo vizinho mais próximo (kNN)

Considere a definição de *D_n^k -outliers* descrita anteriormente. Descreveremos alguns dos principais algoritmos utilizados para encontrá-los.

Os algoritmos descritos nas seções 3.1.1, 3.1.2 e 3.1.3 foram desenvolvidos por Ramaswamy et al. [31], e para sua delimitação, algumas definições são necessárias.

Seja *MINDIST(p, R)* a menor distância entre uma instância p e um retângulo R , de forma que cada ponto em R esteja a uma distância de pelo menos *MINDIST(p, R)* de p , e seja *MAXDIST(p, R)* a maior distância entre uma instância p e um retângulo R , de forma que qualquer ponto em R esteja a uma distância de no máximo *MAXDIST(p, R)* de p . De forma similar definimos *MINDIST(R, S)* e *MAXDIST(R, S)* como a menor e a maior distância entre dois retângulos de limite mínimos R e S , respectivamente.

Considere também a aproximação de um conjunto de instâncias utilizando seu retângulo de limite mínimo (*minimum bounding rectangle*), definido por um retângulo R d -dimensional com vértices $r = \{r_1, r_2, \dots, r_d\}$ e $r' = \{r'_1, r'_2, \dots, r'_d\}$ formando sua diagonal principal, em que d é a dimensão das instâncias do conjunto, e tais que $r_i \leq r'_i$ para todo $1 \leq i \leq d$.

3.1.1 Algoritmo *simple nested-loop*

O algoritmo consiste em calcular $D^k(p)$ para cada instância p do conjunto de entrada e retorna as n instâncias com maior valor de D^k .

Para isso mantém, para cada instância p do conjunto de entrada, uma lista com suas distâncias aos seus k vizinhos mais próximos. Assim, para cada instância $q \neq p$ do conjunto de entrada, se a distância entre p e q for menor que alguma distância na lista, então ela

é adicionada na lista. Se a lista está completa (se já contém k elementos) então a maior distância da lista é removida e a nova distância é inserida. Ao final, a maior distância na lista de vizinhos de p é o valor de $D^k(p)$.

Esse algoritmo possui complexidade computacional $O(N^2)$, onde N é o tamanho do conjunto de entrada [31; 34].

3.1.2 Algoritmo *index-based*

Uma forma de diminuir a complexidade do algoritmo *simple nested-loop* é utilizar uma estrutura de índice multidimensional, como por exemplo uma árvore R^* , que é uma variação de uma árvore R .

Uma árvore R é uma árvore balanceada por altura similar a uma árvore B , e é estruturada de forma a agrupar objetos próximos, representando-os por retângulos de limite mínimos, como ilustrado na figura 6. Cada nó que não é folha da árvore armazena dois tipos de informação: uma maneira de identificar o nó filho e o retângulo de limite de todas as entradas desse nó filho. Cada nó folha, por sua vez, armazena um conjunto de instâncias e seu retângulo de limite mínimo [41].


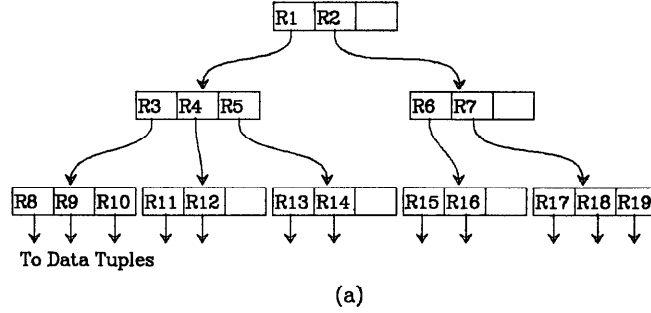


Figura 6: Exemplo simples de uma árvore R bidimensional. Fonte: Antonin Guttman. *R-trees: A Dynamic Index Structure for Spatial Searching*, 1984 [41].

A principal diferença entre as árvores R^* e as árvores R é que as árvores R^* otimizam a cobertura e a sobreposição de cada retângulo de limite mínimo [42].

Utilizando essa estrutura de dados, uma otimização pode ser feita de forma a diminuir o número de cálculos de distância. Suponha que calculamos $D^k(p)$ para uma instância p considerando apenas um subconjunto dos dados de entrada. Esse valor será um limitante superior para o valor real de $D^k(p)$, uma vez que se a menor distância entre p e o retângulo

de limite mínimo de um nó na árvore R^* for maior que o valor de $D^k(p)$ encontrado até o momento, então nenhuma das instâncias na sub-árvore definida por esse nó estarão entre os k vizinhos mais próximos de p . Assim, há uma redução da quantidade de computações das distâncias.

Uma outra otimização pode ser feita considerando que procuramos pelos n melhores candidatos a anomalias. Suponha que os n melhores candidatos sejam armazenados durante cada passo do algoritmo. Seja D_{nmin} o mínimo dentre os valores D^k dessas n instâncias. Se o valor $D^k(p)$ de algum p calculado for menor que D_{nmin} , então p não pode ser uma anomalia, uma vez que D_{nmin} é o menor valor de $D^k(o)$ com o sendo uma anomalia.

O cálculo de $D^k(p)$ de uma instância p pode ser feito utilizando uma lista ligada de nós, que é inicializada com a raiz da árvore R^* , e um *heap* que armazena os k vizinhos mais próximos de p encontrados, inicializado como vazio.

Ao longo do algoritmo, a lista é ordenada de forma crescente em relação a $MINDIST(p, Nó)$, em que $Nó$ é um elemento da lista. Essa distância é calculada utilizando o retângulo de limite mínimo de cada elemento $Nó$ da lista. Já o *heap* armazena os vizinhos de p em ordem decrescente em relação às suas distâncias a p .

Assim, $D^k(p)$ é inicializado com infinito e cada nó da lista é examinado. Se o nó não corresponde a uma folha na árvore R^* , ele é removido da lista, seus filhos são inseridos nela e a lista é reordenada. Além disso, é verificado se $D^k(p)$ é menor ou igual a $MINDIST(p, nó)$ para cada nó da lista. Se for, então nenhuma das instâncias do nó fará parte dos k vizinhos mais próximos de p . Logo o nó é deletado da lista.

Se o nó corresponde a uma folha, então para cada instância q armazenada por esse nó, se a distância entre q e p for menor que $D^k(p)$, q é inserido no *heap* de vizinhos de p . Se o número de elementos no *heap* for maior que k , então o elemento do topo do *heap* é deletado (o elemento cuja distância a p é a maior dentre os elementos do *heap*). Se o número de elementos for igual a k , então $D^k(p)$ recebe o valor da distância entre p e t , onde t é o elemento do topo do *heap*. Além disso, se a qualquer momento $D^k(p)$ for menor que D_{nmin} , então p não pode ser uma anomalia, como discutido anteriormente, e assim o método termina.

Esse algoritmo é mais eficiente do que o algoritmo *simple nested-loop*, mas no pior caso ainda é de ordem quadrática em relação ao tamanho do conjunto de entrada.

3.1.3 Algoritmo *partition-based*

O problema do algoritmo *index-based* é o seu alto custo computacional. Como tipicamente o valor de n é pequeno, muitos cálculos de distâncias não são necessários, levando a um desperdício de computação.

O algoritmo *partition-based* visa eliminar instâncias cujas distâncias aos seus k -ésimos vizinhos mais próximos são muito pequenas, e que portanto são fracas candidatas a anomalias. A principal ideia do algoritmo é particionar o conjunto de entrada dos dados, e dessa forma eliminar cada partição assim que se descobre que ela não contém anomalias.

Para isso utiliza-se um algoritmo de *clustering* para agrupar os dados, de forma que cada *cluster* formado seja uma partição. As partições podem ser armazenadas em uma estrutura de índice, sendo representadas pelos seus retângulos de limite mínimos. A partir disso, para cada partição P , o limitante superior $P.sup$ e o inferior $P.inf$ dos valores de D^k das suas instâncias são calculados, de modo que para cada $p \in P$, $D^k(p) \geq P.inf$ e $D^k(p) \leq P.sup$.

Com esses valores, podemos identificar partições que contém instâncias que são candidatas a anomalias. Suponhamos que temos o valor D_{nmin} como descrito na seção 3.1.2, que é o menor valor de D^k dos n melhores candidatos a anomalias. Então se $P.sup < D_{nmin}$ para alguma partição P , então nenhuma de suas instâncias pode ser anômala. Apenas partições P com $P.sup \geq D_{nmin}$ são partições com instâncias candidatas a anomalias. O cálculo de D_{nmin} pode

ser feito mantendo as partições em ordem decrescente de seus valores de limitante inferior. Sejam $P_1, P_2, \dots, P_l, l \in \mathbb{N}$, partições com os maiores valores de limitante inferior tais que o número de instâncias em cada partição seja no mínimo n . Então $D_{nmin} = \min\{P_i.inf : 1 \leq i \leq l\}$.

As instâncias que devem ser analisadas para o cálculo de $D^k(p)$ para cada $p \in P$, sendo P uma partição, são aquelas que estão em partições cuja distância a P é de no máximo $P.sup$. Sendo assim, seja $P.vizinhos$ o conjunto de tais partições. Desse modo, as partições P com $P.sup$ maior ou igual a D_{nmin} e as partições em $P.vizinhos$ podem ser armazenadas em uma estrutura de índice multidimensional, como uma árvore R^* , e assim, o algoritmo *index-based* pode ser utilizado para computar as n melhores anomalias dentre as instâncias nessas partições. Como em geral o número de instâncias candidatas a anomalias é pequeno, o algoritmo terá uma performance melhor do que quando executado sobre todas as instâncias do conjunto de entrada.

O cálculo de $P.sup$ e $P.inf$ de uma partição P pode ser feito utilizando dois *heaps* que armazenam em ordem decrescente cada partição Q em relação a $MINDIST(P, Q)$ e a $MAXDIST(P, Q)$ e uma lista ligada de nós análoga àquela utilizada no algoritmo descrito na seção 3.1.2. Desse modo, a lista é inicializada com a raiz da árvore R^* , os valores de $P.sup$ e $P.inf$ são inicializados com infinito, e os *heaps* são inicializados como vazios.

Assim, para cada nó da lista, verifica-se se corresponde a um nó folha na árvore R^* . Se sim, então para cada partição Q presente no nó, se $MINDIST(P, Q)$ for menor que $P.inf$, então Q é inserido em um dos *heaps* e dessa forma $P.inf$ é ajustado com o valor de $MINDIST(P, R)$, em que R é a partição no topo do *heap*. Analogamente, se $MAXDIST(P, Q)$ for menor do que $P.sup$, então Q é inserido no outro *heap* e dessa forma $P.sup$ é ajustado com o valor de $MAXDIST(P, R)$, em que R é a partição no topo do *heap*. Se o nó não corresponde a uma folha na árvore R^* , ele é removido da lista, seus filhos são inseridos nela e a lista é reordenada. Além disso, a cada nó examinado, é verificado se para cada elemento $Nó$ na lista, $P.sup \leq MAXDIST(P, Nó)$ e $P.inf \leq MINDIST(P, Nó)$. Se sim, então o nó é deletado da lista.

3.1.4 Algoritmo *nested-loop ANNS*

O algoritmo mais simples para encontrar os D_n^k -outliers é o algoritmo *simple nested-loop* [34]. O algoritmo *index-based* e o algoritmo *partition-based* são algoritmos mais eficientes que o *simple nested-loop*, porém sua boa performance acontece apenas em conjuntos de dados com poucas dimensões.

Um algoritmo simples baseado no *simple nested-loop* foi proposto por Bay et al. [33] que utiliza uma regra simples de *pruning*³ e a aleatoriedade dos dados do conjunto de entrada. Este algoritmo para a maioria dos testes realizados por Bay et al. obteve complexidade linear no tamanho do conjunto de entrada. No pior caso, o algoritmo continua sendo de ordem quadrática.

A regra de *pruning* utilizada é chamada de *Approximate Nearest Neighbour Search – ANNS*. A principal ideia por trás dessa regra é encontrar as n melhores anomalias. Para isso, salva-se um valor c que representa a menor distância entre uma instância e seu k -ésimo vizinho mais próximo encontrado até um certo momento pelo algoritmo. Durante o processo de encontrar $D^k(p)$ para alguma instância p , como $D^k(p)$ tende a diminuir quanto mais vizinhos são processados, se obtivermos um valor de distância entre p e algum vizinho menor que o valor de c , então podemos descartar essa instância p , pois ela não será uma anomalia. Como o valor de c ao longo da execução aumenta, a eficiência do *pruning* aumenta também [33; 34].

³O termo *pruning* não será traduzido para “poda” por ser um termo mais utilizado na área na sua forma em inglês.

O algoritmo pode ser descrito da seguinte forma (Algoritmo 1) [33; 34]:

Algoritmo 1 Algoritmo *nested-loop ANNS*

entrada: k (número de vizinhos mais próximos a ser considerado), n (número de anomalias a serem encontradas), conjunto D de dados de entrada

saída: O (conjunto de anomalias encontradas)

- 1: Inicialize $c = 0$
 - 2: Inicialize O como vazio
 - 3: **para cada** b em D **faça**
 - 4: Inicialize $Vizinhos(b)$ como vazio
 - 5: **para cada** d em D , $d \neq b$ **faça**
 - 6: **se** a quantidade de elementos em $Vizinhos(b)$ for menor que k ou a distância entre b e d for menor que a distância entre b e os elementos de $Vizinhos(b)$ **então**
 - 7: Atualize os valores de $Vizinhos(b)$ com as k instâncias do conjunto $Vizinhos(b) \cup d$ que estão mais próximas de b
 - 8: **se** $D^k(b) < c$ **então**
 - 9: **break**
 - 10: **fim se**
 - 11: **fim se**
 - 12: **fim para**
 - 13: Atualize o conjunto O obtendo as n melhores anomalias entre as que estão no conjunto $O \cup b$
 - 14: Atualize c com o valor da menor distância para os k -ésimos vizinhos mais próximos dos elementos que estão em O
 - 15: **fim para**
-

3.2 Métricas de distância

Um importante fator a ser considerado na utilização de uma técnica de detecção de anomalias baseada em distância é a escolha da função de cálculo da distância utilizada.

As métricas de distância mais utilizadas são as L_k norm⁴. Elas são definidas por:

$$x, y \text{ pertencem a um conjunto de dimensão } d \text{ e } L_k(x, y) = \left(\sum_{i=1}^d |x_i - y_i|^k \right)^{1/k}$$

A métrica L_1 é a distância de Manhattan e a métrica L_2 é a distância Euclidiana.

Muitas técnicas baseadas em distância utilizam como métrica a distância Euclidiana [31; 32; 33]. A distância Euclidiana funciona corretamente e descreve de forma intuitiva a distância para espaços de 2 ou 3 dimensões. Porém em espaços com alta dimensão pode ser difícil a escolha de um métrica de distância.

Segundo os estudos do artigo “*On the Surprising Behavior of Distance Metrics in High Dimensional Space*” [43] a eficácia da L_k norm em espaços com dimensão alta diminui conforme k aumenta. Portanto para espaços com alta dimensão a distância de Manhattan é melhor que a distância Euclidiana. Isso acontece pois:

Seja $Dmax_d^k$ a distância máxima entre um ponto específico (por exemplo a origem) e os N pontos de um conjunto de dimensão d . Seja $Dmin_d^k$ a distância mínima entre um ponto específico (por exemplo a origem) e os N pontos de um conjunto de dimensão d . Temos:

⁴Não foi traduzido por não encontrar uma referência para esse conjunto de métricas em português

- $Dmax_d^1 - Dmin_d^1$ diverge para o infinito quando d aumenta.
- $Dmax_d^2 - Dmin_d^2$ converge para um valor positivo maior que zero quando d aumenta.
- $Dmax_d^k - Dmin_d^k$ ($k > 2$) converge para zero quando d aumenta.

Ou seja, quanto maior o k , menor é a diferença entre a maior distância a um certo ponto e a menor distância para esse mesmo ponto, perdendo assim a ideia de “perto” e “longe”.

Uma outra métrica que pode ser utilizada é a distância de Mahalanobis, que leva em consideração a correlação entre os dados no cálculo da distância e é invariante à escala das variáveis. Sua função é definida por:

$$F(x, y) = \sqrt{(x - y)' \Sigma^{-1} (x - y)},$$

onde $x = (x_1, x_2, \dots, x_d)$ e $y = (y_1, y_2, \dots, y_d)$ são dois vetores de dimensão d e Σ é a matriz de covariância dos dados. Se essa matriz for a identidade, então a distância de Mahalanobis é equivalente à distância Euclidiana [44].

Essa métrica apresenta a desvantagem do alto custo de se calcular a matriz de covariância [45].

4 Implementação do módulo de detecção de anomalias

Nesta seção detalharemos a implementação do método do k -ésimo vizinho mais próximo (kNN) como um módulo de detecção de anomalias para o sistema de validação descrito na seção 2.3.

4.1 Detector de anomalias

O núcleo do sistema de validação estatístico é responsável por conter os algoritmos de detecção de anomalias que são utilizados para a validação dos dados, de forma que seja possível adicionar novos detectores em forma de módulos, desde que suas estruturas respeitem uma certa interface e certas regras.

Para que um módulo possa ser integrado ao sistema, ele deve implementar os seguintes métodos:

- **módulo.criaDetector:** Esse método do módulo visa gerar novos detectores de anomalias (objetos da classe detector). Deve receber de entrada os parâmetros *número_dimensões*, *valor_treinamento*, *absoluto* e *parâmetros_adicionais*. O primeiro é um inteiro que representa o número de dimensões do atributo em questão a ser validado. Já *valor_treinamento* e *absoluto* são um inteiro e um booleano, respectivamente, que juntos indicam a periodicidade com que o treinamento será executado em um detector. O valor de *valor_treinamento* indicará a quantidade de novas operações (adição, alteração ou remoção) sobre instâncias no detector que devem ser realizadas para que o detector possa atualizar seu treinamento. Se o valor de *absoluto* for *Verdadeiro*, então *valor_treinamento* representa o número de operações que devem ser realizadas sobre as instâncias para um novo treinamento, caso contrário (*absoluto* valer *Falso*), representa um percentual em relação à quantidade de instâncias que o detector já possui. Além disso, *parâmetros_adicionais* é um dicionário que permite a entrada de parâmetros, na forma de pares (*chave*, *valor*), que podem ser necessários para o funcionamento de algumas técnicas de detecção de anomalias. Dessa forma, o método retorna um objeto detector criado a partir dessas configurações.
- **detector.adiciona:** Esse método da classe detector permite a inclusão de uma instância de treinamento com sua respectiva marca. Uma marca representa os seguintes valores: *Válido (rotulado)*, que indica que a instância (lote reduzido) foi confirmada como válida por um especialista do domínio; *Supostamente válido (não rotulado)*, que representa que a instância passou pelo processo de validação e foi considerada válida pelo algoritmo; *Inválido (rotulado)*, que indica que o lote foi confirmado como inválido por um especialista do domínio; *Supostamente inválido (não rotulado)*, que representa que a instância passou pelo processo de validação e foi considerada inválida pelo algoritmo e *Desconhecido (não rotulado)*, que indica que não se sabe nada a respeito da validade da instância. O método recebe os parâmetros *instância* e *marca*, em que o primeiro consiste em um objeto que contém o identificador da instância (lote reduzido) e um vetor com as proporções de suas categorias, e o segundo é a marca associada à instância. A instância é armazenada em uma lista de espera para que possa fazer parte do treinamento quando ele for realizado. Caso a instância já esteja no treinamento, a marca associada a ela é substituída pela nova marca recebida.
- **detector.remove:** Esse método do detector permite que uma instância previamente inserida (ou agendada para inserção) e sua respectiva marca sejam removidas do detector. Ele recebe o parâmetro *id_instância*, que representa o id da instância que se deseja

remover. A remoção é colocada em uma lista espera, para que a instância seja removida na próxima vez que o treinamento for realizado.

- **detector.classifica:** Permite a classificação de instâncias pelo detector, utilizando o algoritmo de detecção de anomalias. Esse método recebe o parâmetro *instância*, que é um objeto que contém a identificação da instância a ser classificada e um vetor com as proporções de suas categorias, e retorna *Verdadeiro* ou *1* se a instância for classificada como normal e *Falso* ou *0* se for classificada como anomalia.
- **detector.estaAtivo:** Esse método indica se o detector está ativo, ou seja, se está apto a receber pedidos de validação das instâncias. Ele retorna um booleano *Verdadeiro* se estiver pronto e *Falso* caso contrário. O detector só poderá ser usado se esse método retornar *Verdadeiro*.

Para implementar as funções acima, é sugerido que se tenha duas estruturas de dados gerais: uma lista das instâncias já treinadas e suas respectivas marcas e uma fila das alterações a serem feitas no conjunto de dados.

4.2 Algoritmo kNN

Na seção 3 delimitamos o método do k-ésimo vizinho mais próximo para detecção de anomalias. A ideia por trás da fase de teste desse método se baseia em classificar uma instância como normal se a sua distância ao seu k-ésimo vizinho mais próximo for relativamente pequena, e como anômala caso contrário. Dessa forma, um algoritmo que classifica a instância entre normal ou anômala pode ser descrito da seguinte forma ([Algoritmo 2](#)):

Algoritmo 2 Algoritmo de classificação

entrada: x (elemento a ser classificado), k , c (*threshold*), D (conjunto de dados de entrada)

saída: Anomalia ou normal

- 1: Inicialize $kVizinhos$ como vazio
 - 2: **para cada** b em D **faça**
 - 3: $d = dist(b, x)$
 - 4: **se** a quantidade de elementos em $kVizinhos$ for menor que k ou $d < distKNN(x, kVizinhos)$ **então**
 - 5: Atualize $kVizinhos$ com as k instâncias do conjunto $kVizinhos \cup d$ que estão mais próximas de x
 - 6: **fim se**
 - 7: **fim para**
 - 8: **se** a distância de x ao seu k-ésimo vizinho for menor ou igual a c **então**
 - 9: **devolva** normal
 - 10: **senão**
 - 11: **devolva** anomalia
 - 12: **fim se**
-

Esse algoritmo utiliza um conjunto $kVizinhos$ para armazenar a lista dos k vizinhos mais próximos da instância a ser classificada. Dessa forma, sempre que se encontra um vizinho mais próximo da instância do que os demais que estão na lista, $kVizinhos$ é atualizado. Além disso, dois métodos são utilizados: $dist$, que calcula a distância entre duas instâncias (por exemplo, distância Euclidiana ou de Manhattan) e $distKNN$, que retorna a distância entre a instância e seu k-ésimo vizinho mais próximo encontrado até um certo momento.

Assim, ao final do algoritmo, se a distância entre a instância e seu k -ésimo vizinho mais próximo for menor que um dado valor c , essa distância é considerada relativamente pequena e portanto a instância é classificada como normal. Caso contrário, como anomalia.

Entretanto o funcionamento desse algoritmo depende dos parâmetros c e k . Para determiná-los, utilizaremos na fase de treino o algoritmo descrito na seção 3.1.4, uma vez que é um algoritmo que utiliza uma estrutura de dados simples e se mostra eficiente na prática [33]. Os parâmetros serão então treinados a fim de maximizar a eficiência do algoritmo.

Utilizaremos o índice *F1-Score* [46] como métrica para quantificar a eficiência do algoritmo quando executado com um determinado valor de k . Esse índice é calculado a partir de uma comparação entre os rótulos originais das instâncias e os rótulos obtidos pela execução do algoritmo, considerando os seguintes conceitos:

- Verdadeiros positivos (VP): número de instâncias originalmente anômalas classificadas corretamente pelo algoritmo como anomalias.
- Falsos positivos (FP): número de instâncias originalmente normais classificadas incorretamente pelo algoritmo como anomalias.
- Falsos Negativos (FN): número de instâncias originalmente anômalas classificadas incorretamente pelo algoritmo como normais.
- Verdadeiros negativos (VN): número de instâncias originalmente normais classificadas corretamente pelo algoritmo como normais.

Dessa forma, a métrica *F1-Score* é calculada a partir de dois conceitos: precisão (P) e cobertura (C). A precisão é obtida pela razão entre o número de instâncias corretamente classificadas como anomalias e o número total de instâncias classificadas pelo algoritmo como anomalias. Assim, temos:

$$P = \frac{VP}{VP + FP}$$

Já a cobertura é calculada a partir da razão entre o número de instâncias corretamente classificadas como anomalias e o número de instâncias originalmente anômalas. Temos:

$$C = \frac{VP}{VP + FN}$$

Assim, obtemos o cálculo do índice *F1-Score*:

$$F1-Score = \frac{2 * P * C}{P + C}$$

O cálculo do *F1-Score* deve ser feito para diversos valores de k , e aquele que maximizar o valor do *F1-Score*, será utilizado no algoritmo de classificação (Algoritmo 2). Esse cálculo deve ser repetido a cada novo treinamento.

O parâmetro c será obtido a partir do último valor assumido pela variável c no algoritmo descrito na seção 3.1.4 quando ele é executado com o melhor valor de k (o que maximiza o valor do *F1-Score*). Ou seja, c representará o menor valor de $D^k(p)$ encontrado para determinado k em que p é uma anomalia.

O algoritmo de treinamento pode ser descrito da seguinte maneira ([Algoritmo 3](#)):

Algoritmo 3 Algoritmo de treinamento

entrada: D (conjunto de treino), R (conjunto de rótulos das instâncias de treino), n (quantidade de anomalias no conjunto de treino), N (quantidade de instâncias de treino)

saída: $melhor_k$

```
1: Inicialize  $f1 = 0$ 
2: Inicialize  $melhor\_k = 0$ 
3: para  $k = 1$  até  $\sqrt{N}$  faça
4:    $rotulos = algoritmoSE(D, n, k)$ 
5:    $f1\_aux = F1score(rotulos, R)$ 
6:   se  $f1\_aux > f1$  então
7:      $f1 = f1\_aux$ 
8:      $melhor\_k = k$ 
9:   fim se
10: fim para
11: devolva  $melhor\_k$ 
```

A escolha do intervalo em que k varia foi feita baseando-se em um critério frequentemente utilizado de atribuir $k = \sqrt{N}$, em que N é o número de instâncias do conjunto de entrada, o que torna o processo menos ineficiente do que seria caso k variasse em um intervalo de 1 a N . [47; 48].

A implementação em *Python* [49] dos algoritmos descritos nessa seção está detalhada no apêndice desse trabalho.

5 Estudo de caso

Para testar a implementação do módulo descrita na seção 4 realizamos um estudo de caso, que será descrito nesta seção.

Aplicamos o módulo baseado no modelo gaussiano implementado por Eduardo Dias Filho [9] e o módulo desenvolvido nesse trabalho em diferentes conjuntos de dados para realizar uma análise comparativa entre os dois métodos.

Apêndice

Implementação dos algoritmos

Os algoritmos foram escritos em *Python* [49].

```
def distanceFunction(x, y):
    #distância de manhattan (implementada em scipy.spatial)
    return distance.cityblock(x,y)

#retorna a maior distância entre b e os elementos em N
def maxDist(b, N):
    if(len(N) == 0):
        return 0
    return distanceFunction(b, N[len(N)-1])

#retorna os k elementos em (N U {d}) que estão mais próximos de b
def kNearestNeighbors(k, b, N, d):
    if(len(N) == 0):
        N.append(d)
    else:
        newIndex = -1
        dist = distanceFunction(b, d)
        for i in range(0, len(N)):
            if(dist < distanceFunction(b, N[i])):
                newIndex = i
                break
        # se a distância entre b e d é menor do que alguma
        # distância entre b e um elemento em N,
        # então insere d na posição desse elemento
        if(newIndex != -1):
            N.insert(newIndex, d)
        # caso contrário, insere no fim da lista
        else:
            N.append(d)
        # se a lista ficou com mais que k elementos, retira o último
        # (retira o vizinho mais distante)
        if(len(N) > k):
            N.pop()
    return N

# encontra as n anomalias em D baseando-se no método kNN
def algoritmoANNS(D, k, n):
    c = 0.0
    O = []
    Neighbors = []
    for i in range(0, len(D)):
        b = D[i]
        Neighbors.append([])
        for j in range(0, len(D)):
            if(i == j): continue
            d = D[j]
```

```

        if(len(Neighbors[i]) < k or
           distanceFunction(b,d) < maxDist(b, Neighbors[i])):
            Neighbors[i] = kNearestNeighbors(k, b, Neighbors[i], d)
            if(maxDist(b, Neighbors[i]) < c):
                break
    O = bestOutliers(n, O, b, i, Neighbors)
    c = maxDist(O[0][0], Neighbors[O[0][1]])

    result = ['valid']*len(D)
    for i in range(0, len(O)):
        result.pop(O[i][1])
        result.insert(O[i][1], 'invalid')
    return [result, c]

# retorna as n melhores anomalias em (O U {b}), em relação às distâncias
# aos k-ésimos vizinhos mais próximos de cada instância.
# as instâncias são armazenadas em O em ordem crescente das distâncias aos
# k-ésimos vizinhos mais próximos.
def bestOutliers(n, O, b, i, N):
    if(len(O) == 0):
        O.append([b, i])
    else:
        newIndex = -1
        distKNN = maxDist(b, N[i])
        for k in range(0, len(O)):
            if(distKNN < maxDist(O[k][0], N[O[k][1]])):
                newIndex = k
                break
        if(newIndex != -1):
            O.insert(newIndex, [b, i])
        else:
            O.append([b, i])
        if(len(O) > n):
            O.pop(0)
    return O

# encontra os melhores valores de c e k.
def treinamento(D, R, n):
    f = 0.0
    faux = 0.0
    bestK = 0
    bestC = 0.0
    N = math.ceil(len(D)**(0.5))
    for k in range(1, N):
        [labels, c] = algoritmoANNS(D, k, n)
        faux = F1Score(labels, R)
        if(faux > f):
            f = faux
            bestK = k
            bestC = c
            if(f == 1.0):
                break
    self.k = bestK

```

```

self.c = bestC

# classifica x como normal (1) ou anômala (0).
def classify(x, k, c, D) :
    kNeighbors = []
    for i in range(0, len(D)):
        d = D[i]
        if(len(kNeighbors) < k or distanceFunction(x, d) < maxDist(x, kNeighbors)):
            kNeighbors = kNearestNeighbors(k, x, kNeighbors, d)
    if(maxDist(x, kNeighbors) <= c):
        return 1
    return 0

# VP: Verdadeiro Positivo, FP: Falso Positivo
# VN: Verdadeiro Negativo, FN: Falso Negativo
def F1Score(predicted, original):
    VP, FP, VN, FN = 0, 0, 0, 0
    for i in range(0, len(predicted)):
        if(predicted[i] == 'valid'):
            if(original[i] == 'valid'):
                VN = VN + 1
            else:
                FN = FN + 1
        else:
            if(original[i] == 'valid'):
                FP = FP + 1
            else:
                VP = VP + 1

    if ((VP+FP) == 0 or (VP+FN) == 0):
        return 0

    P = VP/(VP+FP)
    C = VP/(VP+FN)

    if (P+C) == 0:
        return 0

    return 2*P*C/(P+C)

```

Referências

- [1] D.M. Hawkins. *Identification of Outliers*. Monographs on applied probability and statistics. Chapman and Hall, 1980. 1
- [2] H. Jair Escalante. A comparison of outlier detection algorithms for machine learning, 2005. 1
- [3] Paulo M. Mafra, Joni da Silva Fraga, Vinicius Moll, and Altair Olivo Santin. POLVO-IIDS: Um sistema de detecção de intrusão inteligente baseado em anomalias, 2008. 1
- [4] Gerhard Münz, Sa Li, and Georg Carle. Traffic anomaly detection using kmeans clustering, 2007. 1
- [5] Prakash N. Kalavadekar Amruta D. Pawar and Swapnali N. Tambe. A survey on outlier detection techniques for credit card fraud detection. *IOSR Journal of Computer Engineering*, 16(2):44–48, 2014. 1
- [6] Clay Spence, Lucas Parra, and Paul Sajda. Detection, synthesis and compression in mammographic image analysis with a hierarchical image probability model, 2001. 1
- [7] Ji Zhang. Advancements of outlier detection: A survey. *EAI Endorsed Trans. Scalable Information Systems*, 1:e2, 2013. 1, 3, 4, 8, 9, 10, 11, 12, 15
- [8] Pedro L. Takecian. Diretrizes metodológicas e validação estatística de dados para a construção de *data warehouses*, 2014. 1, 14, 15
- [9] Eduardo Dias Filho. Implementação de um sistema de validação estatística configurável de dados, 2014. 1, 26
- [10] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: A survey. *ACM Comput. Surv.*, 41(3):15:1 – 15:58, 2009. 3, 4, 5, 7, 8, 9, 10, 11, 12
- [11] Andrew Ng. Machine learning: Lecture xv. anomaly detection. <https://class.coursera.org/ml-005/lecture/preview>. Universidade de Stanford, Plataforma Coursera. 3
- [12] Josef Burger. A basic introduction to neural networks. <http://pages.cs.wisc.edu/~bolo/shipyard/neural/local.html>. Acessado em 18/05/2015. 4
- [13] David Reby, Sovan Lek, Ioannis Dimopoulos, Jean Joachim, Jacques Lauga, and Stéphane Aulagnier. Artificial neural networks as a classification method in the behavioural sciences. *Behavioural Processes*, 40(1):35 – 43, 1997. 5
- [14] Gábor Horvath. Neural networks in system identification. *NATO SCIENCE SERIES SUB SERIES III COMPUTER AND SYSTEMS SCIENCES*, 185:43–78, 2003. 5
- [15] John Akhilomen. Data mining application for cyber credit-card fraud detection system. In *Proceedings of the 13th International Conference on Advances in Data Mining: Applications and Theoretical Aspects*, ICDM’13, pages 218–228, Berlin, Heidelberg, 2013. Springer-Verlag. 5, 10
- [16] Anup K. Ghosh, Aaron Schwartzbard, and Michael Schatz. Learning program behavior profiles for intrusion detection. In *Proceedings of the 1st Conference on Workshop on Intrusion Detection and Network Monitoring - Volume 1*, ID’99, pages 6–6, Berkeley, CA, USA, 1999. USENIX Association. 5

- [17] Irad Ben-Gal. *Bayesian Networks*. 2008. 6
- [18] Nir Friedman, Dan Geiger, and Moises Goldszmidt. Bayesian network classifiers. *Mach. Learn.*, 29(2-3):131–163, November 1997. 6
- [19] Sakshi Babbar and Sanjay Chawla. On bayesian network and outlier detection. 2010. 6
- [20] Abdallah Abbey Sebyala, Temitope Olukemi, Lionel Sacks, and Dr. Lionel Sacks. Active platform security through intrusion detection using naive bayesian network for anomaly detection. In *In: Proceedings of London communications symposium*, 2002. 6
- [21] M. Taniguchi, M. Haft, J. Hollmen, and V. Tresp. Fraud detection in communication networks using neural and probabilistic methods. In *Acoustics, Speech and Signal Processing, 1998. Proceedings of the 1998 IEEE International Conference on*, volume 2, pages 1241–1244 vol.2, May 1998. 7
- [22] H. Buxton. Advanced visual surveillance using bayesian networks. In *Image Processing for Security Applications (Digest No.: 1997/074), IEE Colloquium on*, pages 9/1–9/5, Mar 1997. 7
- [23] Neethu B. Adaptive intrusion detection using machine learning, 2013. 7
- [24] Wenjie Hu, Yihua Liao, and V. Rao Vemuri. Robust anomaly detection using support vector machines. 7
- [25] Paul Hayton, Bernhard Schölkopf, Lionel Tarassenko, and Paul Anuzis. Support vector novelty detection applied to jet engine vibration spectra. *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS 13*, pages 946–952, 2000. 7
- [26] Luiz Gustavo Moro Senko. Um método baseado em lógica paraconsistente para detecção de inconsistências em classificadores à base de regras, 2006. 7
- [27] Philip K. Chan Matthew V. Mahoney. Learning rules for anomaly detection of hostile network traffic, 2003. 7
- [28] Gregory Cooper Michael Wagner Weng-Keen Wong, Andrew Moore. Rule-based anomaly pattern detection for detecting disease outbreaks. In *Proceedings of the 18th National Conference on Artificial Intelligence*. MIT Press, 2002. Also available online from <http://www.cs.cmu.edu/simawm/antiterror>. 7
- [29] Marco A.F. Pimentel, David A. Clifton, Lei Clifton, and Lionel Tarassenko. A review of novelty detection. *Signal Processing*, 99:215 – 249, 2014. 8, 11, 12
- [30] Edwin M. Knorr, Raymond T. Ng, and Vladimir Tucakov. Distance-based outliers: Algorithms and applications, 2000. 8, 16
- [31] Sridhar Ramaswamy, Rajeev Rastogi, and Kyuseok Shim. Efficient algorithms for mining outliers from large data sets. *SIGMOD Rec.*, 29(2):427–438, May 2000. 8, 16, 17, 20
- [32] Coen van Leeuwen, Arvid Halma, and Klammer Schutte. Anomalous human behavior detection: an adaptive approach, 2013. 8, 20
- [33] Stephen D. Bay and Mark Schwabacher. Mining distance-based outliers in near linear time with randomization and a simple pruning rule, 2003. 8, 19, 20, 24

- [34] Gustavo H. Orair, Carlos H. C. Teixeira, Wagner Meira, Jr., Ye Wang, and Srinivasan Parthasarathy. Distance-based outlier detection: Consolidation and renewed bearing, September 2010. 8, 16, 17, 19, 20
- [35] Markus Breunig, Hans-Peter Kriegel, Raymond T. Ng, and Jörg Sander. Lof: Identifying density-based local outliers. *PROCEEDINGS OF THE 2000 ACM SIGMOD INTERNATIONAL CONFERENCE ON MANAGEMENT OF DATA*, pages 93–104, 2000. 9
- [36] Jian Tang, Zhixiang Chen, Ada Wai-Chee Fu, and David Wai-Lok Cheung. Enhancing effectiveness of outlier detections for low density patterns. In *Proceedings of the 6th Pacific-Asia Conference on Advances in Knowledge Discovery and Data Mining, PAKDD '02*, pages 535–548, London, UK, UK, 2002. Springer-Verlag. 9
- [37] Levent Ertoz, Eric Eilertson, Aleksandar Lazarevic, Pang-Ning Tan, Vipin Kumar, Jai-deep Srivastava, and Paul Dokas. Minds - minnesota intrusion detection system. *Next Generation Data Mining*, pages 199–218, 2004. 9
- [38] Richard J. Bolton, David J. Hand, and David J. H. Unsupervised profiling methods for fraud detection. In *Proc. Credit Scoring and Credit Control VII*, pages 5–7, 2001. 10
- [39] Kingsly Leung and Christopher Leckie. Unsupervised anomaly detection in network intrusion detection using clusters. In *Proceedings of the Twenty-eighth Australasian Conference on Computer Science - Volume 38, ACSC '05*, pages 333–342, Darlinghurst, Australia, Australia, 2005. Australian Computer Society, Inc. 10
- [40] Christopher Kruegel and Giovanni Vigna. Anomaly detection of web-based attacks. In *Proceedings of the 10th ACM Conference on Computer and Communications Security, CCS '03*, pages 251–261, New York, NY, USA, 2003. ACM. 12
- [41] Antonin Guttman. R-trees: A dynamic index structure for spatial searching, 1984. 17
- [42] Norbert Beckmann, Hans-Peter Kriegel, Ralf Schneider, and Bernhard Seeger. The r*-tree: An efficient and robust access method for points and rectangles, May 1990. 17
- [43] Charu C. Aggarwal, Alexander Hinneburg, and Daniel A. Keim. On the surprising behavior of distance metrics in high dimensional spaces, 2001. 20
- [44] Bahadir Durak. A classification algorithm using mahalanobis distance clustering of data with applications on biomedical data sets, 2011. 21
- [45] Victoria Hodge and Jim Austin. A survey of outlier detection methodologies, October 2004. 21
- [46] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, New York, NY, USA, 2008. 24
- [47] Ahmad Basheer Hassanat, Mohammad Ali Abbadi, Ghada Awad Altarawneh, and Ahmad Ali Alhasanat. Solving the problem of the K parameter in the KNN classifier using an ensemble learning approach. *CoRR*, abs/1409.0919, 2014. 25
- [48] Marcel Jirina and Marcel Jirina Jr. Classifiers based on inverted distances, 2011. 25
- [49] Python. <http://www.phyton.org/>. Acessado em 13/10/2014. 25, 27